Proyecto integrador STAI — Plantilla de definición

> **Cómo usar esta plantilla.** Copien este archivo (o péguenlo en un Google Doc compartido) y renómbrenlo con el nombre de su equipo. Llénenlo entre todos. **No es calificable**, pero es el insumo obligatorio para arrancar M1: sin una definición clara, no se puede elegir modelo, dataset ni métrica.
>
> **Sobre el tema.** El tema es de ustedes. No hay una lista cerrada de dominios: elijan algo que de verdad les apasione y que puedan sostener durante todo el semestre, porque cada hito se apila sobre el anterior (modelo → evaluación → RAG → componente visual). Lo único no negociable es que el proyecto tenga **texto de un dominio real** con el que trabajar. Lo demás lo deciden ustedes.
>
> **Meta mínima para la Sesión 2:** llegar al menos hasta la sección **2 · Usuario y decisión** con algo escrito. El resto puede madurar en las semanas siguientes, pero cuanto antes lo cierren, más fácil todo lo que viene.

---

0 · Equipo

- TravelGenie
- Alexandra Hurtado - ahurtadod@eafit.eafit.edu.co
  - Mariana Valderrama - mvalderrc1@eafit.edu.co

- Mariana Valderrama (contacto con el profesor)
- GitHub:
https://github.com/alexahurtado08/TravelGenie_AlexandraHurtado_MarianaValderrama.git
- reunión semanal : jueves / 9am

---

1 · Tema y proyecto

Plataforma basada en inteligencia artificial para optimizar la planificación de viajes mediante modelos predictivos y sistemas de recomendación personalizados.

¿Por qué este tema?

Este proyecto nace de nosotras, de esas conversaciones en las que imaginábamos conocer lugares que solo veíamos en redes sociales o en videos de internet, creyendo que eran viajes reservados para otras personas. Queremos cambiar esa percepción y demostrar que, con una buena planificación, recomendaciones inteligentes y el momento adecuado para comprar, muchos de esos sueños pueden estar mucho más cerca de lo que creemos.

---

2 · Usuario y decisión

- ¿Quién usaría este sistema?

Personas que sueñan con viajar por Colombia, pero que por su presupuesto limitado necesitan planificar cuidadosamente cada decisión para hacer realidad esos viajes.

- ¿Qué decisión o tarea concreta resuelve con la ayuda del sistema?

Identificar el mejor momento para viajar, el destino más conveniente según sus gustos, el clima y su presupuesto, reduciendo costos mediante recomendaciones basadas en inteligencia artificial.

- ¿Qué hace hoy esa persona sin el sistema?

Hoy el usuario busca información en múltiples plataformas, compara precios manualmente, consulta recomendaciones en internet y toma decisiones con información dispersa, lo que hace que la planificación sea lenta y poco eficiente.

---

3 · Tarea central del modelo (M1)

- ¿Qué tipo de tarea es?
predicción, sistema de recomendación y generación , además de preguntas y respuestas

Generación de texto condicionada data-to-text: a partir de datos estructurados de un destino (clima, vuelos, lugares turísticos), el modelo redacta una recomendación de viaje en lenguaje natural.

- ¿Cuál es el input?
un bloque de datos ya consultados (destino, mejor mes por clima, precio/mes más económico de vuelo, hoteles, restaurantes y atractivos disponibles) más la pregunta del usuario en lenguaje natural.
pero para el futuro nos gustaria implementar

- Ciudad de origen en Colombia.
- Presupuesto disponible.
- Fechas o rango de fechas del viaje.
- Duración del viaje.
- Preferencias del usuario (playa, naturaleza, cultura, aventura, gastronomía, ecoturismo, etc.).
- Preferencia de clima (cálido, templado o frío).

- Datos externos: historial de precios de vuelos nacionales, clima, temporadas turísticas

¿Cuál es el output esperado?

una recomendación en texto libre que menciona el destino, el departamento, el mejor mes por clima, el mes/precio más económico de vuelo encontrado, y (cuando hay datos) hoteles, restaurantes y atractivos turísticos.

y en el futuro nos gustaría

- Destinos en Colombia recomendados según el presupuesto y las preferencias.
- Predicción del comportamiento de los precios de vuelos nacionales (si subirán, bajarán o se mantendrán).
- Recomendación del mejor momento para comprar los tiquetes.
- Estimación del costo total del viaje (transporte, alojamiento y actividades).
- Itinerario personalizado con lugares de interés y actividades.
- Recomendaciones de alojamiento y actividades acordes con el presupuesto.

- **¿Qué modelo base candidato?** (DistilBERT / FlanT5-small / TinyLlama / otro — y por qué esa familia)

FlantT5-small se eligió esta familia porque la tarea central (redactar una recomendación en lenguaje natural a partir de datos estructurados) es data-to- text el objetivo de preentrenamiento text-to-text de T5 ya entrena ese tipo de mapeo directamente, a diferencia de un encoder-only ue no genera texto o un decoder-only. que mezcla comprensión y generación en un solo bloque que sería menos natural

---

4 · Dataset

- **¿De dónde sale el texto?

El dataset se construirá a partir de varias fuentes: como Datos abiertos de turismo en Colombia (por ejemplo, datos de destinos y atractivos turísticos publicados por entidades gubernamentales) como DIVIPOLA, Apis del clima para obtener información meteorológica de cada destino como open-Meteo , apis o servicios de busqueda de vuelos para consultar precios históricos y disponibilidad de vuelos nacionales como travelpayouts y datos propios en un futuro que seran obtenidos de los ususarios generados mediante encuestas sobre preferencias de viaje (presupuesto, tipo de turismo, clima preferido, duración del viaje, etc.).

- ¿Cuántos ejemplos, aproximadamente?
384 pares entrada-salida (307 train / 77 validation), cubriendo 16 de 19 destinos colombianos planeados (3 no consiguieron suficientes datos de vuelo en la API).

- **¿En qué idioma(s) está?
repo y documentación en ingles pero el producto en español por que esta orientado para usuarios colombianos

- ¿Hay alguna licencia que restrinja el uso?

Datos abiertos → En este caso al ser gubernamentales son de uso libre.

Las APIs están sujetas a sus términos de uso y límites de consulta.

Los Datos propios pertenecen al proyecto, pueden usarse siempre bajos los términos y condiciones de la protección de datos de usuario

- **¿Algún sesgo o limitación conocida del dataset?**

Si existen algunas limitaciones, por ejemplo el sistema solo contempla destinos de Colombia.

Los precios de vuelos cambian constantemente, por lo que las predicciones pueden perder precisión con el tiempo.

Las recomendaciones dependerán de la calidad y diversidad de los datos recolectados.

Si predominan ciertos perfiles de viajeros (por ejemplo, estudiantes con presupuestos bajos), las recomendaciones podrían favorecer ese tipo de usuario frente a otros.

Datos abiertos → En este caso al ser gubernamentales son de uso libre.

Las APIs están sujetas a sus términos de uso y límites de consulta.

Los Datos propios pertenecen al proyecto, pueden usarse siempre bajos los términos y condiciones de la protección de datos de usuario

además podemos encontrar

- El texto de entrenamiento es sintético (generado por plantilla), no lenguaje natural real de usuarios, el modelo aprende el estilo de las plantillas, no la variedad real con la que la gente pregunta por viajes en estos momentos
- Cobertura geográfica muy desigual: solo 16 de 1.122 municipios de Colombia tienen dataset completo (los que tienen aeropuerto comercial evaluado).
- Los precios de vuelo cambian constantemente y la API solo cachea precios ya buscados por otros usuarios, así que la cobertura mensual por ruta es parcial, no los 12 meses para todas las rutas.
- Colombia tiene municipios homónimos en distintos departamentos (ej. "San Andrés" existe en el archipiélago y en Santander) y esto causó un bug real de datos cruzados en una versión temprana del pipeline, corregido cruzando por (municipio, departamento) en vez de solo por nombre.y vamos a tenerlo presente si se agregan más municipios.

---

5 · Métrica de éxito

- **¿Qué métrica principal medirá si el sistema es útil?**

Para M1: **ROUGE**, comparando el texto generado por el modelo contra la referencia generada por plantilla, sobre el mismo conjunto de validación para el modelo afinado y su baseline.

Para el producto final

- Tasa de aceptación de las recomendaciones: porcentaje de recomendaciones que el usuario considera útiles o decide seguir.
- Error Absoluto Medio (MAE) en la predicción de precios de vuelos, si se implementa esa capacidad predictiva en una entrega posterior..

- **¿Por qué esa métrica y no otra?

ROUGE es la métrica estándar para tareas de generación de texto/resumen cuando se compara contra una referencia encaja con que la tarea de M1 que es una recomendación, no clasificar ni predecir un número. Las métricas de producto (tasa de aceptación, MAE) tienen sentido para etapas futuras del proyecto, cuando existan usuarios reales dandonos feedback

- **¿Cuál sería un baseline razonable con el que compararse?**

Para M1: el mismo modelo base, **FLAN-T5-small sin fine-tuning (zero-shot)**, evaluado con el mismo prompt sobre el mismo conjunto de validación

Para el producto final (a futuro): recomendar los destinos turísticos más populares de Colombia sin considerar presupuesto ni preferencias, y estimar el precio de vuelos con el último valor registrado sin modelos predictivos. este baseline sigue siendo el objetivo de comparación cuando se implementen esas capacidades

---

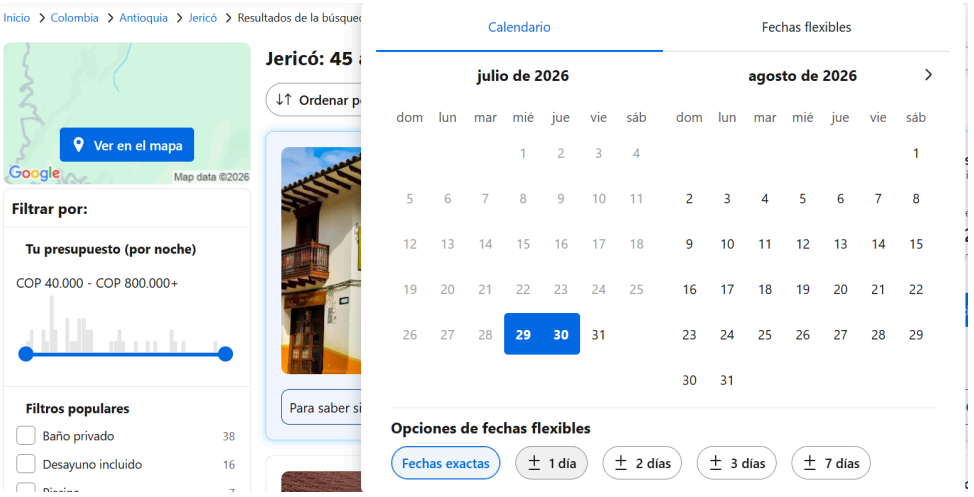
6 · Componente visual (M4) — plan inicial

- **¿Cómo podría integrarse un componente visual a este sistema?** (input visual / output visual / herramienta visual)

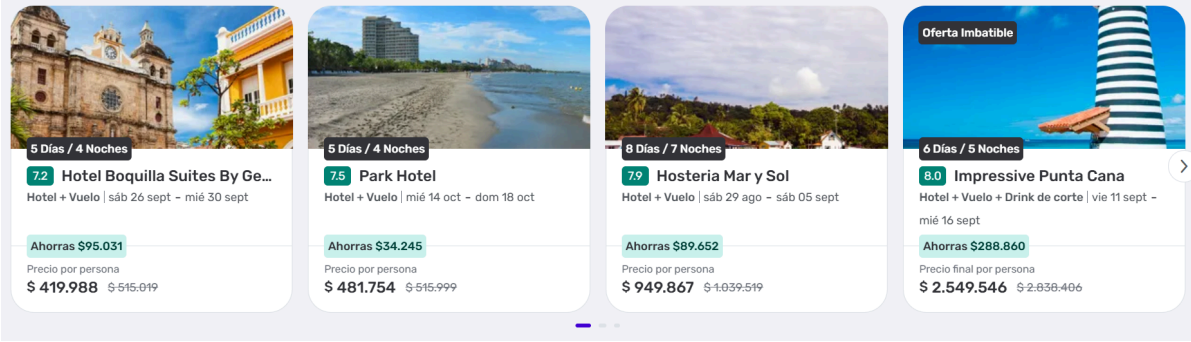
El sistema integrará un componente visual como herramienta de apoyo para la toma de decisiones del usuario. Este incluirá imágenes de los destinos turísticos recomendados, mapas con su ubicación y visualizaciones comparativas de variables como precios estimados de vuelos, condiciones climáticas y temporadas de viaje.

Además, el componente visual permitirá presentar la información de manera más intuitiva mediante gráficos de tendencias de precios, calendarios con las fechas más convenientes para viajar y tarjetas informativas de cada destino con fotografías, actividades destacadas y una estimación del presupuesto. De esta forma, el usuario podrá comparar alternativas y seleccionar la opción que mejor se adapte a sus preferencias y recursos.

- ¿Tienen ejemplos de imágenes representativas?



Paquetes imperdibles





---

7 · Riesgos éticos y de uso

- ¿Quién podría salir perjudicado si el sistema falla?
el usuario en caso de que el sistema falla podria gastar más dinero del que tenía presupuestado o el sistema podría arrojar recomendaciones incoherentes

- ¿Hay grupos de personas en los que probablemente falle más?
en personas con un presupuesto demasiado bajo, o personas que no puedan hacer un buen manejo del sistema

- ¿Cómo se mitigaría esos riesgos?
haciendo que sistema sea intuitivo y que tenga un rango minimo razonable por destino turistico consultado

---

Checklist rápido antes de cerrar

- [ ] El tema tiene texto real de un dominio con el que podemos trabajar.
- [ ] Sabemos quién es el usuario y qué decisión concreta toma.
- [ ] Tenemos al menos una fuente de datos identificada.
- [ ] Tenemos una métrica principal en mente.
- [ ] Todos en el equipo pueden ejecutar un Colab con GPU.